

矩阵的奇异值分解 (singular value decomposition, 简称 SVD) 是线性代数中很重要的内容, 并且奇异值分解过程也是线性代数中相似对角化分解 (也被称为特征值分解, eigenvalue decomposition, 简称 EVD) 的延伸。因此, 以下将从线性代数中最基础的矩阵分解开始讲起, 引出奇异值分解的定义, 并最终给出奇异值分解的低秩逼近问题相关的证明过程。

1 线性代数中的矩阵分解

我们在学习线性代数时, 就已经接触了线性代数中的两个重要定理, 即对角化定理和相似对角化定理, 在这里, 我们先简单地回顾一下这两个定理。另外, 在接下来的篇幅里, 我们所提到的矩阵都是由实数构成的矩阵, 即实矩阵。

给定一个大小为 $m \times m$ 的矩阵 A (是方阵), 其对角化分解可以写成

$$A = U\Lambda U^{-1}$$

其中, U 的每一列都是特征向量, Λ 对角线上的元素是从大到小排列的特征值, 若将 U 记作 $U = (\vec{u}_1, \vec{u}_2, \dots, \vec{u}_m)$, 则

$$AU = A(\vec{u}_1, \vec{u}_2, \dots, \vec{u}_m) = (\lambda_1 \vec{u}_1, \lambda_2 \vec{u}_2, \dots, \lambda_m \vec{u}_m)$$

$$= (\vec{u}_1, \vec{u}_2, \dots, \vec{u}_m) \begin{bmatrix} \lambda_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \lambda_m \end{bmatrix}$$

$$\Rightarrow AU = U\Lambda \Rightarrow A = U\Lambda U^{-1}$$

更为特殊的是, 当矩阵 A 是一个对称矩阵时, 则存在一个对称对角化分解, 即

$$A = Q\Lambda Q^T$$

其中, Q 的每一列都是相互正交的特征向量, 且是单位向量, Λ 对角线上的元素是从大到小排列的特征值。

当然, 将矩阵 Q 记作 $Q = (\vec{q}_1, \vec{q}_2, \dots, \vec{q}_m)$, 则矩阵 A 也可以写成如下形式:

$$A = \lambda_1 \vec{q}_1 \vec{q}_1^T + \lambda_2 \vec{q}_2 \vec{q}_2^T + \dots + \lambda_m \vec{q}_m \vec{q}_m^T$$

举一个简单的例子，如给定一个大小为 2×2 的矩阵 $A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$ ，根据

$$|\lambda I - A| = \begin{vmatrix} \lambda - 2 & -1 \\ -1 & \lambda - 2 \end{vmatrix} = 0 \text{ 求得特征值为 } \lambda_1 = 3, \lambda_2 = 1, \text{ 相应地,}$$

$$\vec{q}_1 = \left(\frac{\sqrt{2}}{2}, \frac{\sqrt{2}}{2} \right)^T, \vec{q}_2 = \left(-\frac{\sqrt{2}}{2}, \frac{\sqrt{2}}{2} \right)^T, \text{ 则}$$

$$A = \lambda_1 \vec{q}_1 \vec{q}_1^T + \lambda_2 \vec{q}_2 \vec{q}_2^T = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}.$$

这样，我们就很容易地得到了矩阵 A 的对称对角化分解。

2 奇异值分解的定义

在上面，对于对称的方阵而言，我们能够进行对称对角化分解，试想：对称对角化分解与奇异值分解有什么本质关系呢？

当给定一个大小为 $m \times n$ 的矩阵 A ，虽然矩阵 A 不一定是方阵，但大小为 $m \times m$ 的 AA^T 和 $n \times n$ 的 $A^T A$ 却是对称矩阵，若 $AA^T = P\Lambda_1 P^T$ ， $A^T A = Q\Lambda_2 Q^T$ ，则矩阵 A 的奇异值分解为

$$A = P\Sigma Q^T$$

其中，矩阵 $P = (\vec{p}_1, \vec{p}_2, \dots, \vec{p}_m)$ 的大小为 $m \times m$ ，列向量 $\vec{p}_1, \vec{p}_2, \dots, \vec{p}_m$ 是 AA^T 的特征向量，也被称为矩阵 A 的左奇异向量 (left singular vector)；矩阵 $Q = (\vec{q}_1, \vec{q}_2, \dots, \vec{q}_n)$ 的大小为 $n \times n$ ，列向量 $\vec{q}_1, \vec{q}_2, \dots, \vec{q}_n$ 是 $A^T A$ 的特征向量，也被称为矩阵 A 的右奇异向量 (right singular vector)；矩阵 Λ_1 大小为 $m \times m$ ，矩阵 Λ_2 大小为 $n \times n$ ，两个矩阵对角线上的非零元素相同（即矩阵 AA^T 和矩阵 $A^T A$ 的非零特征值相同，推导过程见附录 1）；矩阵 Σ 的大小为 $m \times n$ ，位于对角线上的元素被称为奇异值 (singular value)。

接下来，我们来看看矩阵 Σ 与矩阵 AA^T 和矩阵 $A^T A$ 的关系。令常数 k 是矩阵 A 的秩，则 $k \leq \min(m, n)$ ，当 $m \neq n$ 时，很明显，矩阵 Λ_1 和矩阵 Λ_2 的大小不同，但矩阵 Λ_1 和矩阵 Λ_2 对角线上的非零元素却是相同的，若将矩阵 Λ_1 （或矩阵 Λ_2 ）对角线上的非零元素分别为 $\lambda_1, \lambda_2, \dots, \lambda_k$ ，其中，这些特征值也都是非负的，再令矩阵 Σ 对角线上的非零元素分别为 $\sigma_1, \sigma_2, \dots, \sigma_k$ ，则

$$\sigma_1 = \sqrt{\lambda_1}, \sigma_2 = \sqrt{\lambda_2}, \dots, \sigma_k = \sqrt{\lambda_k}$$

即非零奇异值的平方对应着矩阵 Λ_1 （或矩阵 Λ_2 ）的非零特征值，到这里，我们就不难看出奇异值分解与对称对角化分解的关系了，即我们可以由对称对角化分解得到我们想要的奇异值分解。

为了便于理解，在这里，给定一个大小为 2×2 的矩阵 $A = \begin{bmatrix} 4 & 4 \\ -3 & 3 \end{bmatrix}$ ，虽然这个矩阵是方阵，

但却不是对称矩阵，我们来看看它的奇异值分解是怎样的。

由 $AA^T = \begin{bmatrix} 32 & 0 \\ 0 & 18 \end{bmatrix}$ 进行对称对角化分解, 得到特征值为 $\lambda_1 = 32$, $\lambda_2 = 18$, 相应地, 特征向量为 $\vec{p}_1 = (1, 0)^T$, $\vec{p}_2 = (0, 1)^T$; 由 $A^T A = \begin{bmatrix} 25 & 7 \\ 7 & 25 \end{bmatrix}$ 进行对称对角化分解, 得到特征值为 $\lambda_1 = 32$, $\lambda_2 = 18$, 相应地, 特征向量为 $\vec{q}_1 = \left(\frac{\sqrt{2}}{2}, \frac{\sqrt{2}}{2}\right)^T$, $\vec{q}_2 = \left(-\frac{\sqrt{2}}{2}, \frac{\sqrt{2}}{2}\right)^T$. 取 $\Sigma = \begin{bmatrix} 4\sqrt{2} & 0 \\ 0 & 3\sqrt{2} \end{bmatrix}$, 则矩阵 A 的奇异值分解为

$$A = P\Sigma Q^T = (\vec{p}_1, \vec{p}_2) \Sigma (\vec{q}_1, \vec{q}_2)^T$$

$$= \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 4\sqrt{2} & 0 \\ 0 & 3\sqrt{2} \end{bmatrix} \begin{bmatrix} \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ -\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{bmatrix} = \begin{bmatrix} 4 & 4 \\ -3 & 3 \end{bmatrix}.$$

若矩阵 A 不再是一个方阵, 而是一个大小为 3×2 的 $A = \begin{bmatrix} 1 & 2 \\ 0 & 0 \\ 0 & 0 \end{bmatrix}$, 由

$$AA^T = \begin{bmatrix} 5 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \text{ 得到特征值为 } \lambda_1 = 5, \lambda_2 = \lambda_3 = 0, \text{ 特征向量为}$$

$$\vec{p}_1 = (1, 0, 0)^T, \vec{p}_2 = (0, 1, 0)^T, \vec{p}_3 = (0, 0, 1)^T; \text{ 由 } A^T A = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}$$

得到特征值为 $\lambda_1 = 5$, $\lambda_2 = 0$, 特征向量为 $\vec{q}_1 = \left(\frac{\sqrt{5}}{5}, \frac{2\sqrt{5}}{5}\right)^T$,

$$\vec{q}_2 = \left(-\frac{2\sqrt{5}}{5}, \frac{\sqrt{5}}{5}\right)^T, \text{ 令 } \Sigma = \begin{bmatrix} \sqrt{5} & 0 \\ 0 & 0 \\ 0 & 0 \end{bmatrix} \text{ (注意: 矩阵 } \Sigma \text{ 大小为 } 3 \times 2 \text{)}, \text{ 此}$$

时, 矩阵 A 的奇异值分解为

$$A = P\Sigma Q^T = (\vec{p}_1, \vec{p}_2) \Sigma (\vec{q}_1, \vec{q}_2)^T$$

$$= \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \sqrt{5} & 0 \\ 0 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} \frac{\sqrt{5}}{5} & \frac{2\sqrt{5}}{5} \\ -\frac{2\sqrt{5}}{5} & \frac{\sqrt{5}}{5} \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 0 & 0 \\ 0 & 0 \end{bmatrix}.$$

比较有趣的是, 假设给定一个对称矩阵 $A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$, 它是对称矩阵, 则其奇异值分解是怎么样的呢?

分别计算 AA^T 和 $A^T A$ ，我们会发现， $AA^T = A^T A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$
 $= \begin{bmatrix} 5 & 4 \\ 4 & 5 \end{bmatrix}$ ，左奇异向量和右奇异向量构成的矩阵也是相等的，即
 $P = Q = \begin{bmatrix} \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{bmatrix}$ ，更为神奇的是，该矩阵的奇异值分解和对称对角化分解相同，都
是 $A = \begin{bmatrix} \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{bmatrix} \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ -\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{bmatrix}$ 。这是由于对于正定对称矩阵而言，奇异值分解和对称对角化分解结果相同。

3 奇异值分解的低秩逼近

在对称对角化分解中，若给定一个大小为 3×3 的矩阵 $A = \begin{bmatrix} 30 & 0 & 0 \\ 0 & 20 & 0 \\ 0 & 0 & 1 \end{bmatrix}$ ，很显然，矩阵 A 的秩为 $\text{rank}(A) = 3$ ，特征值为 $\lambda_1 = 30$ ， $\lambda_2 = 20$ ， $\lambda_3 = 1$ ，对应的特征向量分别为 $\vec{q}_1 = (1, 0, 0)^T$ ， $\vec{q}_2 = (0, 1, 0)^T$ ， $\vec{q}_3 = (0, 0, 1)^T$ ，考虑任意一个向量 $\vec{v} = (2, 4, 6)^T = 2\vec{q}_1 + 4\vec{q}_2 + 6\vec{q}_3$ ，则

$$\begin{aligned} A\vec{v} &= A(2\vec{q}_1 + 4\vec{q}_2 + 6\vec{q}_3) \\ &= 2\lambda_1\vec{q}_1 + 4\lambda_2\vec{q}_2 + 6\lambda_3\vec{q}_3 = 60\vec{q}_1 + 80\vec{q}_2 + 6\vec{q}_3 \end{aligned}$$

在这里，我们会发现，即使 \vec{v} 是一个任意向量，用矩阵 A 去乘以 \vec{v} 的效果取决于 A 较大的特征值及其特征向量，类似地，在奇异值分解中，较大的奇异值会决定原矩阵的“主要特征”，下面我们来看看奇异值分解的低秩逼近（有时也被称为截断奇异值分解）。需要说明的是，接下来的部分是从文献 [《A Singularly Valuable Decomposition: The SVD of a Matrix》](#) 整理而来的。

给定一个大小为 $m \times n$ 的矩阵 A ，由于 $A = P\Sigma Q^T$ 可以写成

$$A = \sum_{i=1}^k \sigma_i \vec{p}_i \vec{q}_i^T = \sigma_1 \vec{p}_1 \vec{q}_1^T + \sigma_2 \vec{p}_2 \vec{q}_2^T + \dots + \sigma_k \vec{p}_k \vec{q}_k^T$$

其中，向量 $\vec{p}_1, \vec{p}_2, \dots, \vec{p}_k$ 之间相互正交，向量 $\vec{q}_1, \vec{q}_2, \dots, \vec{q}_k$ 之间也相互正交，由内积 $\langle \sigma_i \vec{p}_i \vec{q}_i^T, \sigma_j \vec{p}_j \vec{q}_j^T \rangle = 0, 1 \leq i \leq k, 1 \leq j \leq k, i \neq j$ （有兴趣的读者可以自行推算）得到矩阵 A 的 F - 范数的平方为

$$\begin{aligned}
\|A\|_F^2 &= \|\sigma_1 \vec{p}_1 \vec{q}_1^T + \sigma_2 \vec{p}_2 \vec{q}_2^T + \dots + \sigma_k \vec{p}_k \vec{q}_k^T\|_F^2 \\
&= \sigma_1^2 \|\vec{p}_1 \vec{q}_1^T\|_F^2 + \sigma_2^2 \|\vec{p}_2 \vec{q}_2^T\|_F^2 + \dots + \sigma_k^2 \|\vec{p}_k \vec{q}_k^T\|_F^2 \\
&= \sigma_1^2 + \sigma_2^2 + \dots + \sigma_k^2 = \sum_{i=1}^r \sigma_i^2
\end{aligned}$$

知道了矩阵 A 的 F - 范数的平方等于其所有奇异值的平方和之后，假设 $A_1 = \sigma_1 \vec{p}_1 \vec{q}_1^T$ 是矩阵 A 的一个秩一逼近（rank one approximation），那么，它所带来的误差则是 $\sigma_2^2 + \sigma_3^2 + \dots + \sigma_k^2$ （ k 是矩阵 A 的秩），不过如何证明 $A_1 = \sigma_1 \vec{p}_1 \vec{q}_1^T$ 是最好的秩一逼近呢？

由于 $\|A - A_1\|_F^2 = \|P\Sigma Q^T - A_1\|_F^2 = \|\Sigma - P^T A_1 Q\|_F^2$ （证明过程见附录 2），令 $P^T A_1 Q = \alpha \vec{x} \vec{y}^T$ ，其中， α 是一个正常数，向量 \vec{x} 和 \vec{y} 分别是大小为 $m \times 1$ 和 $n \times 1$ 的单位向量，则

$$\|\Sigma - P^T A_1 Q\|_F^2 = \|\Sigma - \alpha \vec{x} \vec{y}^T\|_F^2 = \|\Sigma\|_F^2 + \alpha^2 - 2\alpha \langle \Sigma, \vec{x} \vec{y}^T \rangle$$

单独看大小为 $m \times n$ 的矩阵 Σ 和 $\vec{x} \vec{y}^T$ 的内积 $\langle \Sigma, \vec{x} \vec{y}^T \rangle$ ，我们会发现，

$$\begin{aligned}
\langle \Sigma, \vec{x} \vec{y}^T \rangle &= \sum_{i=1}^k \sigma_i x_i y_i \leq \sum_{i=1}^k \sigma_i |x_i| |y_i| \\
&\leq \sigma_1 \sum_{i=1}^k |x_i| |y_i| = \sigma_1 \langle \vec{x}^*, \vec{y}^* \rangle \\
&\leq \sigma_1 \|\vec{x}^*\| \cdot \|\vec{y}^*\| \leq \sigma_1 \|\vec{x}\| \cdot \|\vec{y}\| = \sigma_1
\end{aligned}$$

其中，需要注意的是， x_i, y_i 分别是向量 \vec{x} 和 \vec{y} 的第 i 个元素；向量

$\vec{x}^* = (|x_1|, |x_2|, \dots, |x_k|)^T$ 的大小为 $k \times 1$ ，向量

$\vec{y}^* = (|y_1|, |y_2|, \dots, |y_k|)^T$ 的大小也为 $k \times 1$ ，另外，以 \vec{x}^* 为例，

$\|\vec{x}^*\| = \sqrt{x_1^2 + x_2^2 + \dots + x_k^2}$ 是向量的模，则 $\|A - A_1\|_F^2$ （残差矩阵的平方和）为

$$\|\Sigma - \alpha \vec{x} \vec{y}^T\|_F^2 \geq \|\Sigma\|_F^2 + \alpha^2 - 2\alpha \sigma_1 = \|\Sigma\|_F^2 + (\alpha - \sigma_1)^2 - \sigma_1^2$$

当且仅当 $\alpha = \sigma_1$ 时， $\|A - A_1\|_F^2$ 取得最小值 $\sigma_2^2 + \sigma_3^2 + \dots + \sigma_k^2$ ，此时，矩阵 A 的秩一逼近恰好是 $A_1 = \sigma_1 \vec{p}_1 \vec{q}_1^T$ 。

当然，我们也可以证明 $A_2 = \sigma_2 \vec{p}_2 \vec{q}_2^T$ 是矩阵 $A - A_1$ 的最佳秩一逼近，以此类推，

$A_r = \sigma_r \vec{p}_r \vec{q}_r^T, r < k$ 是矩阵 $A - A_1 - A_2 - \dots - A_{r-1}$ 的最佳秩一逼近。由于矩阵 $A_1 + A_2 + \dots + A_r$ 的秩为 r ，这样，我们可以得到矩阵 A 的最佳秩 r 逼近 (rank- r approximation)，即

$$A \approx A_1 + A_2 + \dots + A_r = \sum_{i=1}^r A_i.$$

这里得到的矩阵 P_r 的大小为 $m \times r$ ，矩阵 Σ_r 的大小为 $r \times r$ ，矩阵 Q_r 的大小为 $n \times r$ ，矩阵 A 可以用 $P_r \Sigma_r Q_r^T$ 来做近似。

用低秩逼近去近似矩阵 A 有什么价值呢？给定一个很大的矩阵，大小为 $m \times n$ ，我们需要存储的元素数量是 mn 个，当矩阵 A 的秩 k 远小于 m 和 n ，我们只需要存储 $k(m + n + 1)$ 个元素就能得到原矩阵 A ，即 k 个奇异值、 km 个左奇异向量的元素和 kn 个右奇异向量的元素；若采用一个秩 r 矩阵 $A_1 + A_2 + \dots + A_r$ 去逼近，我们则只需要存储更少的 $r(m + n + 1)$ 个元素。因此，奇异值分解是一种重要的数据压缩方法。

另外，关于奇异值分解的应用将在该系列后续文章中进行详述。

附录 1：相关链接：[Largest eigenvalues of AA^T equals to A^T A](#)，截图如下：

For any $m \times n$ and $n \times m$ matrices A and B , the nonzero eigenvalues of AB and BA are the same. Namely, if $ABv = \lambda v$ with $\lambda \neq 0$ and $v \neq 0$, then $Bv \neq 0$ and $BA(Bv) = B(ABv) = \lambda Bv$.

share cite improve this answer

answered Apr 24 '15 at 6:32



Robert Israel

254k ● 15 ■ 167 ▲ 379

附录 2：求证： $\|P\Sigma Q^T - A_1\|_F^2 = \|\Sigma - P^T A_1 Q\|_F^2$ ，其中， $QQ^T = I$ ， $PP^T = I$ 。

证明： $\|P\Sigma Q^T - A_1\|_F^2$

$$\begin{aligned} &= \text{trace} \left((P\Sigma Q^T - A_1) (P\Sigma Q^T - A_1)^T \right) \\ &= \text{trace} \left((P\Sigma Q^T - A_1) QQ^T (P\Sigma Q^T - A_1)^T \right) \\ &= \text{trace} \left((P\Sigma - A_1 Q) (\Sigma^T P^T - Q^T A_1^T) \right) \\ &= \text{trace} \left((\Sigma^T P^T - Q^T A_1^T) (P\Sigma - A_1 Q) \right) \\ &= \text{trace} \left((\Sigma^T P^T - Q^T A_1^T) PP^T (P\Sigma - A_1 Q) \right) \end{aligned}$$

$$= \text{trace} \left((\Sigma^T - Q^T A_1^T P) (\Sigma - P^T A_1 Q) \right)$$

$$= ||\Sigma - P^T A_1 Q||_F^2.$$